Traitement de données géospatiales

avec Parquet et DuckDB

👋 Florent Fougères

Développeur SIG chez Oslandia

@florentfougeres

@florentfougeres

florent.fougeres@gmail.com

Florent Fougères

Plan du cours

1. Introduction au format Parquet
2. Le SGBD DuckDB : présentation et caractéristiques
3. Performances et benchmarks
4. Cas d'usage en SIG
5. La complémentarité Parquet + DuckDB
6. Exercices pratiques

1. Introduction au format Parquet

Qu'est-ce que Parquet ?

- **Format de fichier open source**
- Développé par la **Fondation Apache**
- Conçu pour stocker et accéder à de **grandes quantités de données**
- **Architecture orientée colonnes**
- **Compression efficace**
- Extension **Geoparquet** pour les géométries spatiales

Architecture orientée colonnes

Format traditionnel (orienté lignes) :

```
Ligne 1: nom, prénom, ville, code_postal
Ligne 2: nom, prénom, ville, code_postal
Ligne 3: nom, prénom, ville, code_postal
```

Parquet (orienté colonnes) :

```
Colonne nom: [valeur1, valeur2, valeur3, ...]
Colonne prénom: [valeur1, valeur2, valeur3, ...]
Colonne ville: [valeur1, valeur2, valeur3, ...]
```

Avantages de l'architecture colonnes

✅ **Meilleure compression**

- Les données d'une même colonne sont souvent similaires

✅ **Lecture optimisée**

- Ne lit que les colonnes nécessaires

✅ **Performance analytique**

- Idéal pour les agrégations et statistiques

Organisation en dataset

Un dataset Parquet peut être un **dossier de fichiers** :

```
/mon_dataset/
  ├── partie_1.parquet
  ├── partie_2.parquet
  ├── partie_3.parquet
  └── partie_4.parquet
```

Avantages :

- Traitement en parallèle (chunks)
- Gestion efficace de gros volumes
- Meilleure performance globale

Geoparquet

> https://geoparquet.org

Extension de Parquet pour les **données géospatiales**

- Stockage des géométries spatiales
- Compatible avec tous les types géométriques
- Métadonnées spatiales (CRS, bbox, etc.)
- Tous les avantages de Parquet préservés

Benchmark : Comparaison des formats

Données : Localités mondiales > 1 000 habitants

Format	Taille du fichier
GeoJSON	~100 MB
CSV	~80 MB
Parquet	**~20 MB**

→ Gain de taille : 5x plus compact que GeoJSON

Limite importante de Parquet

⚠️ **Parquet = format d'échange**

- Pas un format de travail
- Pas un format de traitement
- Nécessite un système optimisé pour l'exploiter

Solution : DuckDB

02

Le SGBD DuckDB : présentation et caractéristiques

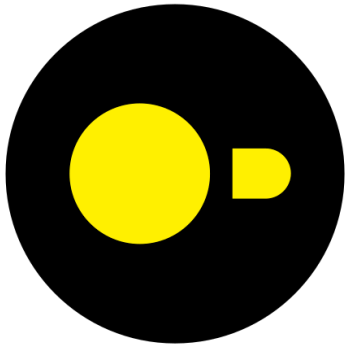

DuckDB

Qu'est-ce que DuckDB ?

Système de gestion de base de données relationnelle (SGBDR)

- Écrit en **C++**
- Licence **MIT** (open source)
- Base de données en **fichier portable**
- Version stable : **1.4.4**
- **Sans serveur** (serverless)

Pourquoi choisir DuckDB ?

✅ **Sans serveur (Serverless)**

- Pas de processus serveur à gérer
- Configuration minimale

✅ **Installation rapide**

- Mise en place en quelques minutes

✅ **Fichier portable**

- Facilite le partage et la sauvegarde

Pourquoi choisir DuckDB ? (suite)

✅ Langage SQL standard

- Facile si vous connaissez SQL
- Nombreuses fonctions analytiques

✅ Lecture directe de fichiers

- Requêtes directes sur Parquet, CSV, etc.
- Pas d'import nécessaire

✅ Extension spatiale

- Fonctions GIS basées sur GEOS
- Compatible avec PostGIS

Extension spatiale de DuckDB

Fonctionnalités avancées pour le SIG :

- Grande variété de fonctions spatiales (GEOS)
- **Noms identiques à PostGIS** (migration facilitée)
- **Indexation spatiale**
- Lecture/écriture de nombreux formats
- Support des **drivers GDAL**

Installation de l'extension spatial

```
INSTALL spatial;
```

> A faire qu'une seule fois sur le poste

Chargement de l'extension spatial

```
LOAD spatial;
```

> Il s'agit de l'équivalent du `CREATE EXTENSION postgis` sur une base dans PostgreSQL

OLAP vs OLTP

DuckDB est optimisé pour l'OLAP

https://fr.wikipedia.org/wiki/Traitement_analytique_en_ligne

> En informatique, et plus particulièrement dans le domaine des bases de données, le traitement analytique en ligne (anglais online analytical processing, OLAP) est un type d'application informatique orienté vers l'analyse sur-le-champ d'informations.

- OLAP: Traitement analytique en ligne (*online analytical processing*)
- OLTP: Traitement transactionnel en ligne (*online transaction processing*)

OLAP vs OLTP

OLAP (DuckDB)	OLTP (PostgreSQL)
Requêtes analytiques complexes	Transactions rapides
Lecture de gros volumes	Nombreuses écritures
Peu de mises à jour	Mises à jour fréquentes
Agrégations et analyses	Intégrité transactionnelle

Performance : Architecture colonnes

DuckDB excelle pour :

- Traitement de **grands volumes** de données
- Données de **plusieurs gigaoctets**
- Tables de **plusieurs millions de lignes**
- **Requêtes analytiques** et agrégations

Benchmark : DuckDB vs PostGIS

Données : 13,1 millions de bâtiments (GeoJSON 6,3 GB)

Opération	DuckDB	PostGIS
Intégration	4 min	5 min 30 s
Calcul de buffer	**38 s**	1 min 54 s
Ajout colonne + surface	**2 s**	2 min 58 s

⚠️ **DuckDB ne remplace pas PostGIS**

Ils ont des cas d'usage différents et complémentaires.

Limitations de DuckDB (1/2)

❌ Pas de support des projections

- Pas de transformation de systèmes de coordonnées
- Données doivent être dans la même projection

❌ Mono-utilisateur et local

- Usage local uniquement
- Pas de multi-utilisateurs simultanés

❌ Verrouillage en lecture

- Base verrouillée lors des lectures

Limitations de DuckDB (2/2)

❌ **Pas de gestion des droits**

- Pas de système de permissions
- Pas de gestion de rôles

❌ **Projet jeune**

- Évolution rapide
- API peut changer

❌ **OLAP uniquement**

- Pas pour : écritures fréquentes, transactions concurrentes, haute disponibilité

Utilisation de DuckDB

Interface en ligne de commande (CLI)

- Linux, macOS, Windows

Langages de programmation

- Python, R, Java, Node.js, Rust...

Dans QGIS

- QDuckDB

Utilisation de DuckDB

IDE

- DBeaver
- DataGrip (freeware)
- Beekeeper Studio

Web

Permet grace à DuckDB WASM

- DuckDB Shell
- DuckUI
- Avec la CLI via `duckdb -ui`

03

Cas d'usage en SIG

Plugin QDuckDB pour QGIS

Intégration de DuckDB dans QGIS

- Développement financé par l'**IFREMER**
- Mode **lecture seule** actuellement
- Chargement de couches depuis DuckDB
- Disponible dans le gestionnaire d'extensions QGIS

📺 Vidéo de démonstration

Exemple 1 : Créer une table géographique depuis un CSV

Créer une couche spatiale depuis un CSV avec X,Y :

```
SELECT
    *,
    ST_Point(x, y) as geometry
FROM read_csv('fichier.csv')
WHERE x IS NOT NULL
  AND y IS NOT NULL;
```

Exemple 2 : Conversion Shapefile → GPKG

Convertir un Shapefile en GeoPackage :

```
COPY (
    SELECT * FROM ST_Read('input.shp')
) TO 'output.gpkg'
WITH (FORMAT GDAL, DRIVER 'GPKG');
```

Exemple 3 : Parquet → Shapefile avec filtre

Créer un Shapefile depuis Parquet avec filtre spatial :

```
COPY (
    SELECT *
    FROM read_parquet('data.parquet')
    WHERE ST_Within(
        geometry,
        ST_MakeEnvelope(xmin, ymin, xmax, ymax)
    )
) TO 'filtered.shp'
WITH (FORMAT GDAL, DRIVER 'ESRI Shapefile');
```

Génération de tuiles vectorielles

Nouveauté depuis DuckDB 1.4

✅ **Avantages :**

- Performance élevée pour la génération de tuiles
- Intégration facile dans des pipelines
- Alternative légère aux solutions traditionnelles

📂 Exemple par Max Gabrielsson

04

Complémentarité Parquet + DuckDB

Le duo gagnant

Format ouvert (Parquet)

- Stockage compact
- Compression efficace
- Portabilité

+

Base de données in-process (DuckDB)

- Requêtes SQL puissantes
- Performance élevée
- Facilité d'utilisation

= Efficacité maximale

Workflow recommandé

1. Stockage en Parquet

- Compression et archivage
- Partage et échange de données

2. Traitement avec DuckDB

- Analyses et requêtes complexes
- Transformations et conversions

3. Export vers format métier

- GeoPackage pour QGIS
- Shapefile pour compatibilité
- GeoJSON pour le web

Cas d'usage idéaux ✅

DuckDB + Parquet est parfait pour :

- Analyse exploratoire de données (EDA)
- Prototypage rapide d'analyses spatiales
- Traitement batch de grandes données
- Conversions de formats en masse
- Génération de rapports analytiques
- Scripts ETL
- Travail en local sur données volumineuses
- Recherche et développement

Cas d'usage à éviter ❌

Ne PAS utiliser pour :

- Applications web avec accès concurrent
- Systèmes nécessitant haute disponibilité
- Applications transactionnelles (CRUD intensif)
- Cas nécessitant gestion fine des droits utilisateurs

05

Conclusion

Points clés à retenir

1. **Parquet** : format de stockage efficace pour grandes données
2. **DuckDB** : SGBD performant pour l'analyse volumineuse
3. **Extension spatiale** : capacités GIS avancées
4. **Parquet + DuckDB** : duo idéal pour l'analyse géospatiale
5. **Complémentarité** : ne remplace pas PostgreSQL/PostGIS

Perspectives

DuckDB est un projet jeune et dynamique

- Évolution rapide
- Écosystème grandissant
- Nouvelles fonctionnalités régulières
- Intégrations multiples

→ Un outil à surveiller de près dans le domaine géospatial

Ressources

Documentation et communauté :

- Site officiel : https://duckdb.org
- Documentation : https://duckdb.org/docs
- Extension spatiale : https://duckdb.org/docs/extensions/spatial
- GitHub : https://github.com/duckdb/duckdb
- Une liste sélectionnée de bibliothèques, d'outils et de ressources DuckDB : https://github.com/davidgasquez/awesome-duckdb
- Plugin QGIS QDuckDB : https://plugins.qgis.org/plugins/qduckdb/
- Article Géotribu : https://geotribu.fr/articles/2023/2023-12-19_duckdb-donnees-spatiales/